

Прогноз температуры почвы по метеоданным RP5

Учебный проект по анализу данных

19 декабря 2025 г.

Источник данных

- ▶ Метеоданные получены с RP5 (архивы наблюдений метеостанций)
- ▶ Температура почвы — из отдельных файлов замеров
- ▶ Данные имеют временную структуру и пропуски

Мотивация проекта

- ▶ Температура почвы важна для изучения поведения вечной мерзлоты
- ▶ Влияет разрушение городской инфраструктуры
- ▶ Задача прогноза нетривиальна из-за инерционности процесса

Цель проекта

Построить модель машинного обучения, прогнозирующую температуру почвы на основе метеорологических параметров.

Линейная регрессия используется как базовая (baseline) модель.

Подготовка данных

- ▶ Объединение данных RP5 и замеров по дате и времени
- ▶ Очистка пропусков
- ▶ Кодирование категориальных признаков
- ▶ Масштабирование признаков
- ▶ Добавление лагов температуры воздуха

Модель


- ▶ Линейная регрессия (метод наименьших квадратов)
- ▶ Лаги температуры воздуха: $t - 1, t - 2, t - 3$
- ▶ Разбиение данных: 70% обучение / 30% контроль
- ▶ Без перемешивания (учёт временной структуры)

Реальные значения и предсказания




Модель хорошо воспроизводит общий тренд, но сглаживает
резкие изменения.

Ошибка предсказания во времени




Наблюдается автокорреляция ошибок.

Распределение ошибок




Ошибки сосредоточены около нуля, но присутствуют выбросы.

Диаграмма y_{true} vs y_{pred}



Линейная модель плохо воспроизводит экстремальные значения.

Коэффициенты модели



Наибольший вклад вносят параметры давления и лаги температуры воздуха.

Количественные результаты

- ▶ $MAE \approx 0.8^\circ C$ — приемлемая абсолютная ошибка
- ▶ $RMSE < 1^\circ C$
- ▶ $R^2 < 0$ — модель плохо объясняет дисперсию

MAE и R^2 отражают разные аспекты качества модели.

Итоговые выводы

- ▶ Линейная регрессия — корректный baseline
- ▶ Добавление лагов улучшает MAE и RMSE
- ▶ Отрицательный R^2 указывает на ограничения модели
- ▶ Ошибки автокоррелированы

Перспективы развития

- ▶ Увеличение числа лагов
- ▶ Добавление сезонных признаков
- ▶ Ridge / ElasticNet
- ▶ Нелинейные модели (градиентный бустинг)